拡散モデルを利用した強化学習による 歩行者混雑環境下での移動ロボットナビゲーション

Mobile Robot Navigation in Crowded Environments with Pedestrians Using Diffusion-Based Reinforcement Learning

○学　富田　湧 (九州大)　　正　松本　耕平（九州大）
学　兵頭　侑樹（九州大）　正　倉爪　亮（九州大）

We propose a novel method that applies diffusion-based reinforcement learning to mobile robot navigation in dynamic environments with pedestrians. The proposed method employs Q-Score Matching as the learning framework for the Actor-Critic model in its architecture. To demonstrate the effectiveness of our approach, we conduct both simulations and real-world experiments.

Key Words: Social Navigation, Reinforcement Learning, Diffusion Models

1　緒言

近年，人手不足を背景に，様々な分野で移動ロボットの導入が進められている．特に病院やショッピングモールなどの人が多く存在する環境へ移動ロボットを導入するためには，ロボットが歩行者が行き交う混雑した状況でも衝突を回避しながらスムーズに移動する手法が必要不可欠である．このような歩行者混雑環境下におけるロボットナビゲーションの研究はソーシャルナビゲーションと呼ばれ，深層強化学習を利用した手法が提案されている [1, 2, 3]．深層強化学習では，対象とする環境でモデルを動作させ，データ収集しながら逐次的に学習を行う．学習を効率的に行うためには，多様な経験が必要であり，分散的に期待値の高い行動を生成することが望ましい．しかしながら，従来の正規分布などの単純な確率分布を用いた行動生成では，多様かつ期待値の高い行動の生成は困難であり，十分なデータを集めるためには多くの時間を要する．一方，近年，生成モデルなどに利用され注目を集めている拡散モデルでは，ノイズの付与されたデータをもとに戻す逆拡散過程を学習することで，多様なデータを生成可能であり，強化学習に応用することで，性能の向上が期待されている．本研究では，歩行者が行き交う環境における移動ロボットナビゲーションタスクに拡散モデルを用いたオンライン強化学習を適用する．

2　拡散モデルを用いた強化学習

2.1　拡散モデル

拡散モデルは，拡散過程と逆拡散過程から構成される．拡散過程では目標分布から得られるサンプルに少しずつノイズを付与していくことで，最終的にサンプルを完全なノイズにする．逆拡散過程では，ノイズの付与されたサンプルから学習モデルを用いてノイズ除去を行う．この 2 つの過程をタイムステップ τ を変更しながら反復的に行うことで完全なノイズから目標サンプルを生成する．

拡散モデルの生成過程，逆拡散過程を式 1，2 に示す．ここで，α_τ はサンプルにノイズを付与する割合を決定するハイパーパラメータである．

$$\boldsymbol{x}_\tau = \sqrt{\alpha_\tau}\boldsymbol{x}_{\tau-1} + \sqrt{1-\alpha_\tau}\boldsymbol{\epsilon}, \quad \text{where } \boldsymbol{\epsilon} \sim \mathcal{N}(\boldsymbol{0}, \boldsymbol{I}), \tag{1}$$

$$\boldsymbol{x}_{\tau-1} = \frac{\boldsymbol{x}_\tau - \sqrt{1-\alpha_\tau}\boldsymbol{\mu}_\theta}{\sqrt{\alpha_\tau}}, \tag{2}$$

$\boldsymbol{\mu}_\theta$ はモデルの出力である．学習においては，式 3 のように付与されたノイズを推定し，ノイズとモデルの 2 乗誤差を最小化する．

$$L(\theta) = \mathbb{E}[||\boldsymbol{\epsilon} - \boldsymbol{\mu}_\theta(\sqrt{\alpha_\tau}\boldsymbol{x}_0 + \sqrt{1-\alpha_\tau}\boldsymbol{\epsilon}, \tau)||^2]. \tag{3}$$

この学習過程を通してノイズを予測し，式 2 で段階的にノイズ除去を行うことで完全なノイズから多様なサンプルを確率的に生成することができる．

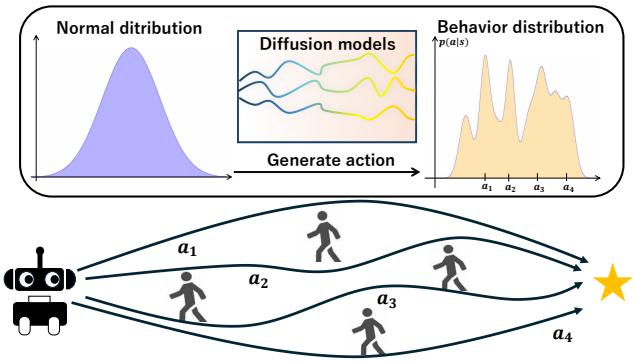

Fig.1: Conceptual diagram of diffusion policies.Diffusion models convert normal distribution to multimodal distribution step by step (upper side). By using diffusion models, the robots generate various actions (lower side).

2.2　強化学習のための拡散モデルを用いた行動生成

図 1 に拡散モデルを用いた強化学習の概念図を示す．拡散モデルでは，複雑な確率分布を表現可能である．この構造を強化学習に応用することで，行動空間が連続である場合においても，無限に存在する行動の中から期待値の高い多様な行動を生成することができる．様々な期待値の高い行動を生成することで，豊富な経験を獲得できるため，学習性能の向上が期待される．

3　提案手法

3.1　問題設定

本研究では，X-Y 平面の歩行者が複数存在する環境で，ロボットが衝突を回避しながら目的地へ到達するタスクを考える．報酬，状態，行動を以下のように定義する．

- 状態：歩行者とロボットの位置と速度データを状態として扱う．各歩行者，ロボットの観測はベクトル $(p_x^i, p_y^i, v_x^i, v_y^i)$ であり，i 番目の歩行者またはロボットにおいて，(p_x^i, p_y^i) は位置，(v_x^i, v_y^i) は速度を表す．
- 行動：ホロノミックな全方位移動ロボットを想定し，2 次元空間におけるロボットの x 軸方向の入力速度 v_x と y 軸方向の入力速度 v_y からなる 2 次元ベクトル (v_x, v_y) を用いる．
- 報酬：式 (4) に本研究における報酬を示す．d_t はロボットと周囲の歩行者間の最小距離を表し，p_t^r は時刻 t における

ロボットの位置，p_g はロボットの目標位置を示す．

$$R(s_t) = \begin{cases} -0.25 & \text{if } d_t < 0 \\ -0.1 + d_t/2 & \text{else if } d_t < 0.2 \\ 1 & \text{else if } p_t^r = p_g \\ 0 & \text{otherwise} \end{cases}, \quad (4)$$

3.2 モデルアーキテクチャ

提案手法は Actor-Critic の方式をとり，価値関数と方策関数をそれぞれ学習する．価値関数には Multilayer Perceptron (MLP)，方策関数には拡散モデルを用いる．ロボットの状態 s_t^r と歩行者の状態 s_t^p はグラフ畳み込みを用いて統合され，価値関数と方策関数に入力される．図 2 にモデルアーキテクチャを示す．

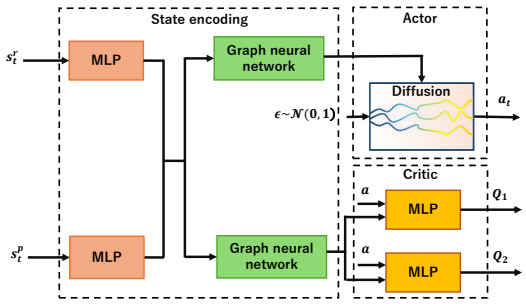

Fig.2: Architecture of the proposed method.

3.3 学習手法

学習は Q-Score Matching(QSM) [4] で行う．この学習手法をアルゴリズム 1 に示す．価値関数はベルマン方程式に基づき，生成される行動の行動価値を学習する．方策関数では，拡散モデルのスコアが推定された行動価値の勾配に近づくように学習する．

Algorithm 1: Training algorithm using QSM

Initialize score network Ψ_θ and critic networks Q_{ϕ^1}, Q_{ϕ^2}
Set the parameter values of the target critics $Q_{\phi',1}$ and $Q_{\phi',2}$ equal to the main critics
for $i = 1$ **to** E **do**
  Conduct exploration until finishing an episode
  After finishing an episode, store the trajectory of $(\boldsymbol{s}_t, \boldsymbol{a}_t, r_t, \boldsymbol{s}'_t)$ to the replay buffer $\mathcal{D}$
  Sample a batch $\mathcal{B} = \{(\boldsymbol{s}, \boldsymbol{a}, r, \boldsymbol{s}')\}$ from $\mathcal{D}$
  Sample actions for computing targets $\hat{\boldsymbol{a}}' \sim \pi_\theta(\cdot \mid \boldsymbol{s}')$
  Calculate targets for the Q-function
  $y(r, \boldsymbol{s}') = r + \gamma \left(\min_{i=1,2} Q_{\phi',i}(\boldsymbol{s}', \hat{\boldsymbol{a}}') \right)$
  Update critics by minimizing
  $L_{\text{critic}} = \frac{1}{|\mathcal{B}|} \sum (Q_{\phi^i}(\boldsymbol{s}, \boldsymbol{a}) - y(r, \boldsymbol{s}'))^2 \quad \text{for } i = 1, 2$
  Update the socre network by minimizing
  $L_{\text{QSM}} = \frac{1}{|\mathcal{B}|} \sum \|\Psi_\theta(\boldsymbol{s}, \boldsymbol{a}) - \alpha \nabla_a Q(\boldsymbol{s}, \boldsymbol{a})\|^2$
  Update the target critic by polyak averaging
  $\phi'^{,i} \leftarrow \rho \phi'^{,i} + (1 - \rho)\phi_i \quad \text{for } i = 1, 2$
end

このように価値の行動勾配を学習することによってランダムなノイズから価値が高い行動への移動量を算出することができ，価値の高い行動を確率的に生成することができる．

4 シミュレーション実験

本節では提案手法のシミュレーション実験を行い，本手法の学習性能，汎化性能を評価する．

4.1 シミュレーション環境

シミュレーション実験では，CrowdNav 環境の circle crossing シナリオを利用する [1, 2]．このシナリオでは，ロボットは初期位置 $(x, y) = (0, -4)$ からゴール地点 $(x, y) = (0, 4)$ を目指して進む．歩行者は ORCA [5] に従って行動し，初期化時に半径 4m の円上にランダムに配置される．比較手法としては，Behavior Cloning (BC)，連続行動空間における重み付き回帰を用いた強化学習手法，CAWR [3], AWR [6], QVWR [7], AWAC [8]，拡散モデルを用いた強化学習手法，DIPO [9]，QVPO [10] を用いる．学習はロボットを ORCA に基づいて動作させ，2,000 エピソード分の遷移情報を事前に収集しておき，100,000 エピソード分のオンライン学習を行った．性能評価は 5 つの異なるシードで学習を行ったモデルを，500 パターンのテストケースを用いて比較した．

4.2 学習性能評価

本節では提案手法の学習性能を定性的・定量的に評価する．表 1 に提案手法と比較手法の各指標を示す．表中の値はランダムシード 5 つの平均を示しており，± は標準偏差を表す．図 3 に提案手法の軌跡の一部，図 4 に平均収益 1000 エピソード毎の割引報酬値の推移を示す．

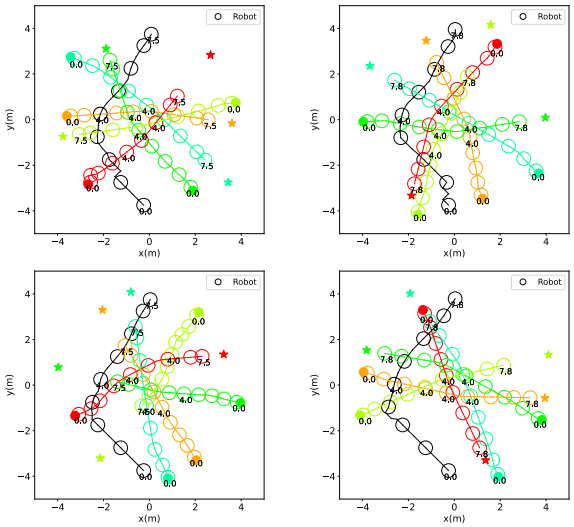

Fig.3: Sample trajectories of the results of the proposed method. The black trajectory describes the robot, and the colored trajectories describe pedestrians.

提案手法は歩行者を回避して目標位置に到達するような方策を獲得できていることがわかる．

Table 1: Numerical comparison of the proposed method and other methods.

Method	Success [%]	Collision [%]	Exec. time [s]	Avg. return
BC	77.28 ± 0.17	22.56 ± 0.18	10.06 ± 0.61	0.377 ± 0.001
AWR	87.60 ± 1.96	12.36 ± 1.97	11.44 ± 1.80	0.466 ± 0.009
CAWR	61.00 ± 0.57	35.28 ± 0.45	11.98 ± 8.13	0.236 ± 0.001
QVWR	62.48 ± 3.84	34.24 ± 3.86	11.44 ± 5.63	0.245 ± 0.020
AWAC	71.08 ± 2.91	28.92 ± 2.91	11.32 ± 5.83	0.327 ± 0.011
DIPO	80.80 ± 1.97	17.52 ± 1.42	11.29 ± 1.26	0.327 ± 0.011
QVPO	98.24 ± 0.02	1.68 ± 0.01	9.75 ± 0.97	0.618 ± 0.001
Proposed	$\mathbf{98.28 \pm 0.03}$	$\mathbf{1.60 \pm 0.03}$	$\mathbf{8.70 \pm 0.07}$	$\mathbf{0.647 \pm 0.000}$

この表より提案手法がすべての指標において最も良い性能を示していることがわかる．

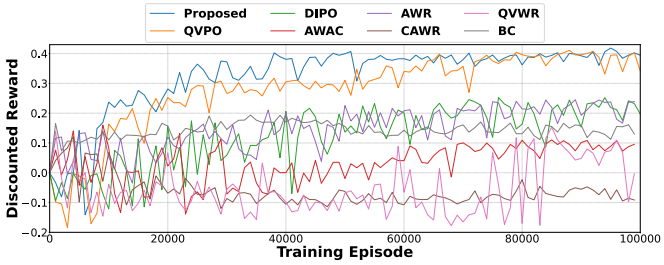

Fig.4: Transition of discauted reward by training step.

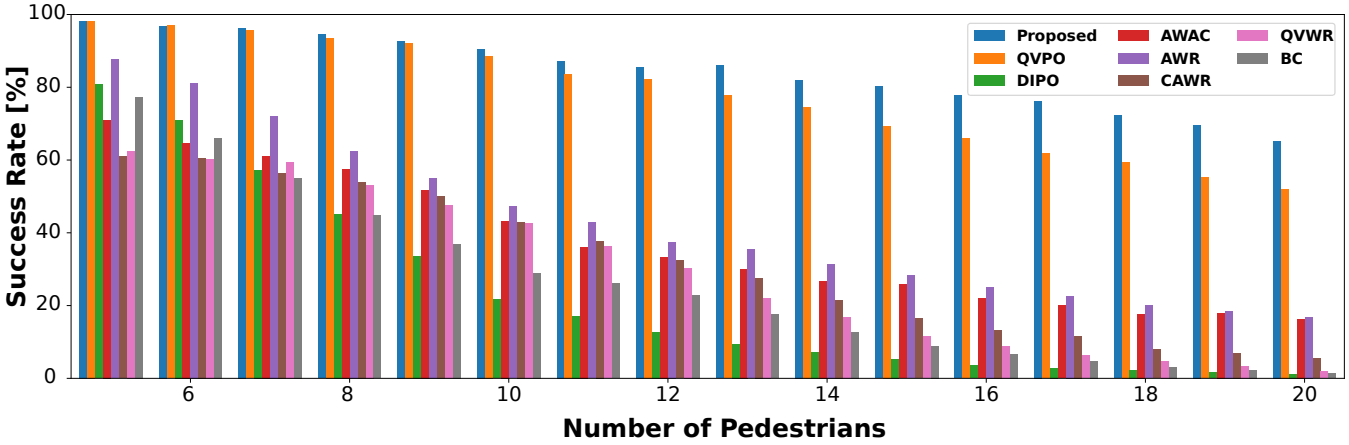

Fig.5: Comparison of success rate while changing the number of pedestrians.

図 4 の割引報酬推移を見ると，学習回数 10,000 回程度までは BC が最も高く，次に重み付き回帰を用いた強化学習手法，拡散モデルを用いた強化学習となっている．しかし，学習回数が増加していくと，提案した手法が最も割引報酬の値が高くなることがわかり，十分に学習回数を重ねることでモデルの性能が最も高くなることが示された．

4.3 汎化性能評価

次にモデルの汎化性能を評価するために circle crossing シナリオの歩行者を 5 から 20 人に 1 人ずつ増加させていきながら評価を行った．成功率の推移を図 5 に示す．この結果から提案手法が最も異なる歩行者数，歩行者モデルにおいても成功率を保つことができることが示された．また，QVPO も歩行者からロボット位置が見える設定では，提案手法と同等の性能を示したが，人数を増やした際に提案手法よりも性能が低下していることがわかる．これは，QVPO はデータセットに対する重み付き回帰に基づいて学習を行うため，学習環境と異なる環境である場合，性能が低下していると考えられる．

4.4 行動の多様性評価

次に提案手法の行動の多様性を評価する．評価方法としては学習後のモデルを用いて，学習時と同じシナリオで行動生成を 10,000 回行う．この行動データをもとに行動分布のヒートマップを作成し，定性的に多峰性を持った分布になっているか確認する．作成した行動分布を図 6 にを示す．

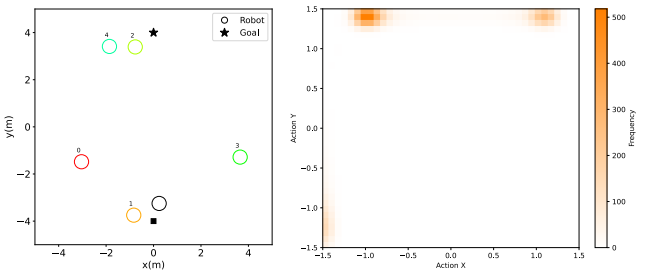

Fig.6: Heatmap of the distribution of generated actions (right) and the situation at that time (left). The left figure shows the position of the robot as a black circle and the position of the pedestrians as colored circles. The right figure shows the frequency of action generation, where dark orange indicate higher frequencies.

図 6 を見ると，生成された行動が，左上，左下，右上の 3 つの箇所に分布してことがわかり，提案手法の行動分布は多様性を獲得できている．

5 実機実験

本節では歩行者混雑環境下での移動ロボットナビゲーションにおける実機を用いた動作実験を行う．まず，実験環境について説明を行い，実験結果を示す．

5.1 ロボット構成

本研究では提案手法を実世界に適用するにあたって，外界センサに 2D-LiDAR (UST-20LX)，演算処理コンピュータに Jetson AGX Orin を搭載した 4 輪メカナムホイールロボットを利用した．演算処理コンピュータには提案手法の他に，通信のためのソフトウェアとして ROS2 Humble，歩行者検知システムでは DR-SPAAM，自己位置推定のための AMCL (Adaptive Monte Carlo Localization) を実装した．

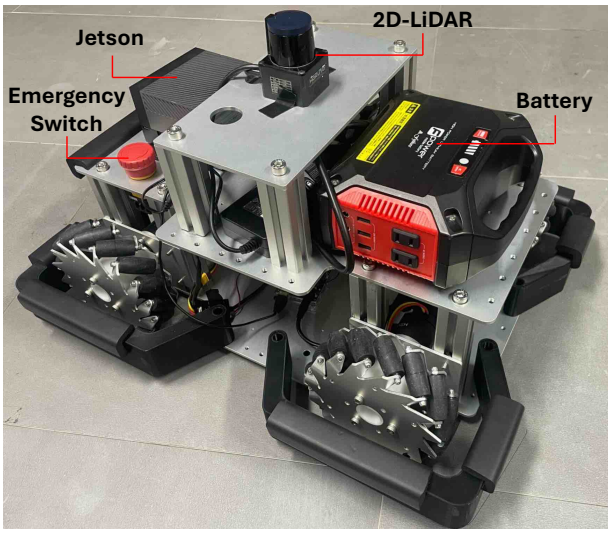

Fig.7: Appiarance of the robot system.

5.2 実験環境

実験環境は 9 × 7.5m の部屋にロボット，歩行者を 4.1 節の学習環境で使用した circle crossing の動きを再現するように配置した．ロボットのゴールはスタート位置から 8m 先の点とし，事前に環境情報のマップを作成しホイールオドメトリ，2D-LiDAR，マップから AMCL を用いて自己位置推定を行っている．使用した部屋の様子と実験環境を図 8 に示す．

5.3 実験結果

図 9 に実験の様子を示す．提案手法は実世界においてもスムーズに衝突を回避し目的地に到達することができた．提案手法が 1 回の行動生成にかかる平均時間は 0.28 秒，最大時間は 0.41 秒であった．しかし，学習を行ったシミレーション環境での 1 ステップの時間間隔は 0.25 秒のため，ロボットの行動生成がシミレー

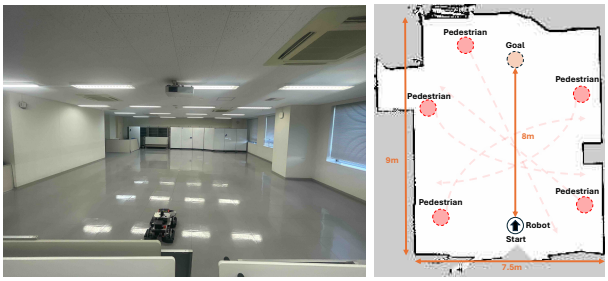

Fig.8: Environment for the real-world experiment and the layout of pedestrians.

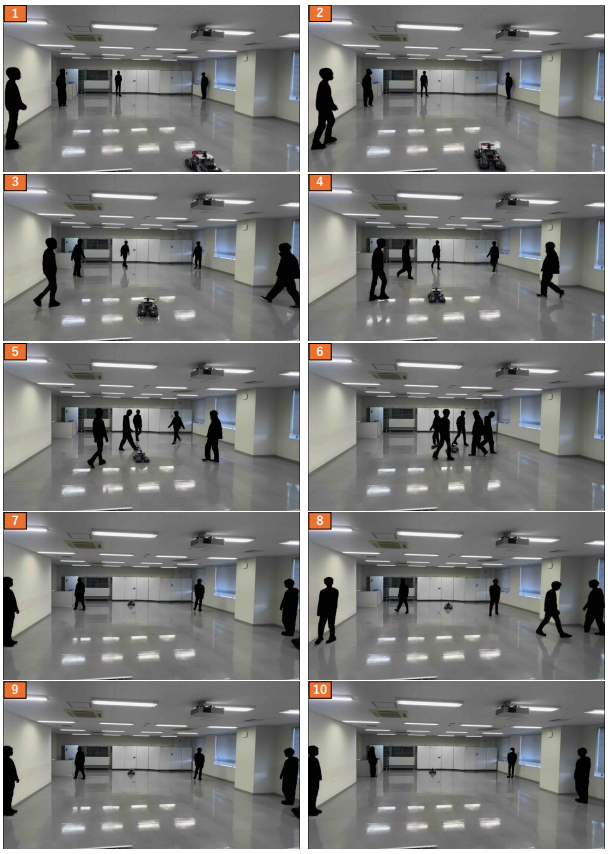

Fig.9: Scenes of the real-world experiment.

ション環境のステップ数に間に合わない現象が見られた．そのため，行動生成の速度改善が必要であり，今後の課題となっている．

6　まとめと今後の展望

本研究では，拡散モデルを用いた強化学習を歩行者が行き交う環境での移動ロボットナビゲーションに適用した．提案手法は，グラフ畳み込みを用いてロボットと歩行者の潜在特徴を統合し，アーキテクチャ全体を Q-Score Matching を用いて学習させた．また，シミレーション実験，実機実験によって本手法の有効性を確認した．

今後の展望としては，行動生成速度の改善が挙げられる．5 節の実機実験では，学習環境での時間間隔に行動生成が間に合わず，処理の高速化が必要であることが分かった．現在のモデルでは 100 ステップかけて逆拡散過程を行い，行動を生成している．そのため，このステップを小さくすることで，実世界においても所望時間以内の処理速度で高い性能を持った学習ができると考えている．

謝辞

本研究の一部は，JSPS 科研費 JP20H00230 の助成を受けたものである．

参考文献

[1] Changan Chen, Yuejiang Liu, Sven Kreiss, and Alexandre Alahi. Crowd-Robot Interaction:Crowd-aware Robot Navigation with Attention-based Deep Reinforcement Learning. In *Proceedings of the IEEE International Conference on Robotics and Automation (ICRA)*, pp. 6015–6022, 2019.

[2] Changan Chen, Sha Hu, Payam Nikdel, Greg Mori, and Manolis Savva. Relational Graph Learning for Crowd Navigation. In *Proceedings of the IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, pp. 10007–10013, 2020.

[3] Xueyou Zhang, Wei Xi, Xian Guo, Yongchun Fang, Bin Wang, Wulong Liu, and Jianye Hao. Relational Navigation Learning in Continuous Action Space among Crowds. In *Proceedings of the IEEE International Conference on Robotics and Automation (ICRA)*, pp. 3175–3181, 2021.

[4] Michael Psenka, Alejandro Escontrela, Pieter Abbeel, and Yi Ma. Learning a Diffusion Model Policy from Rewards via Q-Score Matching. In *Proceedings of the International Conference on Machine Learnin (ICML)*, pp. 41163–41182, 2024.

[5] Jur Van Den Berg, Stephen J. Guy, Ming Lin, and Dinesh Manocha. Reciprocal n-Body Collision Avoidance. In *Proceedings of the International Symposium of Robotic Research*, pp. 3–19, 2011.

[6] Xue Bin Peng, Aviral Kumar, Grace Zhang, and Sergey Levine. Advantage-Weighted Regression: Simple and Scalable Off-Policy Reinforcement Learning. *CoRR*, Vol. abs/1910.00177, , 2019.

[7] Piotr Kozakowski, Lukasz Kaiser, Henryk Michalewski, Afroz Mohiuddin, and Katarzyna Kańska. Q-Value Weighted Regression: Reinforcement Learning with Limited Data. In *Proceedings of the International Joint Conference on Neural Networks (IJCNN)*, pp. 1–8, 2022.

[8] Ashvin Nair, Murtaza Dalal, Abhishek Gupta, and Sergey Levine. Accelerating online reinforcement learning with offline datasets. *CoRR*, Vol. abs/2006.09359, , 2020.

[9] Long Yang, Zhixiong Huang, Fenghao Lei, Yucun Zhong, Yiming Yang, Cong Fang, Shiting Wen, Binbin Zhou, and Zhouchen Lin. Policy Representation via Diffusion Probability Model for Reinforcement Learning. *CoRR*, Vol. abs/2305.13122, , 2023.

[10] Shutong Ding, Ke Hu, Zhenhao Zhang, Kan Ren, Weinan Zhang, Jingyi Yu, Jingya Wang, and Ye Shi. Diffusion-based Reinforcement Learning via Q-weighted Variational Policy Optimization. In *Advances in Neural Information Processing Systems (NeurIPS)*, pp. 53945–53968, 2024.