拡散モデルを利用した深層強化学習による歩行者混雑環境下での移動ロボットナビゲーション

第 2 報　拡散モデルの条件付けガイダンスによる適応的行動生成

○富田 湧（九大）　松本 耕平（九大）　兵頭 侑樹（九大）　倉爪 亮（九大）

Mobile robot navigation in dynamic environments with pedestrians is a key challenge for deploying mobile robots. While online deep reinforcement learning (DRL) enables efficient training in simulation without human supervision, it is technically difficult to achieve reliable performance in environments with complex and varied spatial arrangements of static obstacles. To address this, we propose a novel method that integrates diffusion models into online DRL. By guiding the generative process to adapt to new conditional distributions, our approach enables robust navigation in unseen environments with static obstacles, without compromising performance.

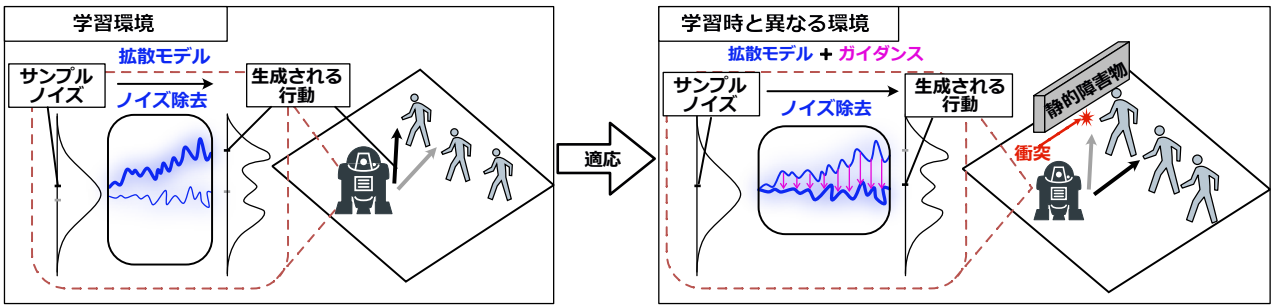

図 1: 拡散モデルと条件付けガイダンスによる障害物回避

1.　緒言

近年, 人手不足を背景に, 様々な分野で移動ロボットの導入が進められている．特に病院やショッピングモールなどの人が多く存在する環境へ移動ロボットを導入するためには, ロボットが歩行者が行き交う混雑した状況でも衝突を回避しながらスムーズに移動する手法が必要不可欠である．このような混雑環境下におけるロボットナビゲーションの研究はソーシャルナビゲーションと呼ばれ, 近年, 深層強化学習を利用した手法が提案されている [1, 2, 3]．深層強化学習では, 対象とする環境でモデルを動作させ, データ収集しながら逐次的に学習する．また, シミュレーションにより対象となる環境を作成することで, 人的リソースを利用せず, ロボットを繰り返し学習可能である．しかしながら, 学習環境と異なる環境に適応することが難しく, 新しいタスクや未学習の環境に対して大きく性能を低下させてしまう．また, 壁などの静的障害物が存在する環境の場合, 壁の配置や大きさ, 形状は様々であり, それらすべてのパターンを作成し学習することは非効率である．

一方, 近年, 生成モデルなどに利用され注目を集めている拡散モデルでは, データにノイズを付与し，段階的にノイズを除去する逆拡散過程を学習することで, 多様なデータを生成可能である. また, 学習済み拡散モデルに条件付けを行い, 生成過程を誘導することで条件付き確立に基づくデータを生成することができる．

本研究では, 歩行者混雑環境下における移動ロボットナビゲーションに拡散モデルを用いたオンライン強化学習を適用後, 学習した生成過程を新しく条件付けされた確率分布に従う方向へ誘導することで新しいタスクや未学習の環境にも適応可能なナビゲーション手法を提案する．

2.　拡散モデルを用いたナビゲーション

2.1　拡散モデル

拡散モデルは, 拡散過程と逆拡散過程から構成される. 拡散過程では目標分布から得られるサンプルに少しずつノイズを付与していくことで, 最終的にサンプルを完全なノイズにする. 逆拡散過程では, ノイズの付与されたサンプルから学習モデルを用いてノイズ除去を行う．この 2 つの過程をタイムステップ τ を変更しながら反復的に行うことで完全なノイズから目標サンプルを生成する．

拡散モデルの生成過程, 逆拡散過程を式(1),(2)に示す. ここで,α_τ はサンプルにノイズを付与する割合を決定するハイパーパラメータである．

$$\boldsymbol{x}_\tau = \sqrt{\alpha_\tau}\boldsymbol{x}_{\tau-1} + \sqrt{1-\alpha_\tau}\boldsymbol{\epsilon}, \quad \text{where } \boldsymbol{\epsilon} \sim \mathcal{N}(\boldsymbol{0}, \boldsymbol{I}), \tag{1}$$

$$\boldsymbol{x}_{\tau-1} = \frac{\boldsymbol{x}_\tau - \sqrt{1-\alpha_\tau}\boldsymbol{\epsilon}_\theta}{\sqrt{\alpha_\tau}}. \tag{2}$$

ここで,$\boldsymbol{\epsilon}_\theta$ はモデルの出力である．学習においては, 式(3)のように付与されたノイズを推定し, ノイズとモデルの 2 乗誤差を最小化する．

$$L(\theta) = \mathbb{E}[||\boldsymbol{\epsilon} - \boldsymbol{\epsilon}_\theta(\sqrt{\alpha_\tau}\boldsymbol{x}_0 + \sqrt{1-\alpha_\tau}\boldsymbol{\epsilon}, \tau)||^2]. \tag{3}$$

この学習過程を通してノイズを予測し, 式(2)で段階的にノイズ除去を行うことで完全なノイズから多様なデータを確率的に生成することができる.

2.2 ガイダンスを用いた拡散モデルの行動生成

図 1に拡散モデル, ガイダンスを用いた行動生成の概念図を示す．拡散モデルでは, 多様な行動を確率的に生成可能であり, ベイズ則に基づいた条件付きスコア関数を用いて学習後に新しい条件に従うように行動生成を誘導することができる．この行動生成の誘導を利用し, 学習後に新しい条件に対応するように生成過程を誘導することで学習時と異なる静的障害物が存在する環境においても衝突を回避し, 目的地へ到達することが期待される.

3. 提案手法

3.1 問題設定

本研究では,X-Y 平面の歩行者が複数存在する環境で, ロボットが衝突を回避しながら目的地へ到達するタスクを考える．報酬, 状態, 行動を以下のように定義する.

- 状態：歩行者とロボットの位置と速度データを状態として扱う．各歩行者, ロボットの観測はベクトル $(p_x^i, p_y^i, v_x^i, v_y^i, p_{wx}, p_{wy})$ であり,i 番目の歩行者またはロボットにおいて,(p_x^i, p_y^i) は位置,(v_x^i, v_y^i) は速度,(p_{wx}, p_{wy}) は最も近い壁の位置を表す.
- 行動：ホロノミックな全方位移動ロボットを想定し,2 次元空間におけるロボットの x 軸方向の入力速度 v_x と y 軸方向の入力速度 v_y からなる 2 次元ベクトル (v_x, v_y) を用いる.
- 報酬：式 (4) に本研究における報酬を示す．$\boldsymbol{p}_w$ はロボットと周囲の歩行者間の最小距離を表し,$\boldsymbol{p}_t^r$ は時刻 t におけるロボットの位置,$\boldsymbol{p}_g$ はロボットの目標位置を示す.

$$R(\boldsymbol{s}_t) = \begin{cases} -0.25 & \text{if } d_t < 0 \\ -0.1 + d_t/2 & \text{else if } d_t < 0.2 \\ 1 & \text{else if } \boldsymbol{p}_t^r = \boldsymbol{p}_g \\ 0 & \text{otherwise} \end{cases}, \quad (4)$$

3.2 拡散モデルの学習

本研究では使用する方策モデルとして, 拡散モデルのスコア関数を行動価値関数へ反復的に近づけるように最適化する Q-Score Matching (QSM) [4] を用いてオンライン強化学習を 100,000 エピソードで事前に学習したモデルを利用する [5]．ここで, この方策モデルでは静的障害物が存在していない環境で学習されている．そのため, ロボット位置に対して相対的な歩行者位置, ゴール位置を状態状態 $\boldsymbol{s}_t$ として受け取り, 報酬 $R(\boldsymbol{s}_t)$ を最大化することを目的として学習を行う．式(5)に Q-Score Matching の損失関数を示す.

$$L_{\mathrm{QSM}} = \mathbb{E}[\|\Psi_\theta(\boldsymbol{s}_t, \boldsymbol{x}_\tau, \tau) - \frac{1}{\beta}\nabla_{\boldsymbol{x}_\tau} Q(\boldsymbol{s}_t, \boldsymbol{x}_\tau)\|^2]. \quad (5)$$

ここで,$\boldsymbol{x}_\tau$ はシミュレーション環境内の時刻の行動 $\boldsymbol{a}_t$ に拡散ステップ τ のノイズを付与した値である. このように学習を行うことで方策の確率分布 π_θ は式(6)に従う.

$$\pi_\theta(\boldsymbol{s}_t) \propto \exp\left(\frac{1}{\beta}Q(\boldsymbol{s}_t, \boldsymbol{a}_t)\right). \quad (6)$$

ここで,$Q(\boldsymbol{s}_t, \boldsymbol{a}_t)$ は状態 $\boldsymbol{s}_t$ で行動 $\boldsymbol{a}_t$ をとったときに得られる報酬の期待値を推定するように学習されており, 同じ状態 $\boldsymbol{s}_t$ においても行動 $\boldsymbol{a}_t$ によって様々な値を取る．$\pi_\theta(\boldsymbol{s}_t)$ の分布は行動価値関数の指数関数値に比例し多峰性を表現可能である. また,β は温度係数と呼ばれこの値を大きくするとなめらかな分布になりエントロピーが増加し, 小さくすると分布はとがったような形となりエントロピーが減少する.

3.3 拡散モデルの行動生成誘導

拡散モデルの行動生成を誘導する手法として Clean Guidance [6] を採用している．式(7)に, ベイズ則に基づいた拡散モデルの条件付きスコア関数を示す.

$$\nabla_{\boldsymbol{x}_\tau} \log p_\tau(y|\boldsymbol{x}_\tau, \boldsymbol{s}_t) = \nabla_{\boldsymbol{x}_\tau} \log p_\tau(\boldsymbol{x}_\tau, \boldsymbol{s}_t) + \nabla_{\boldsymbol{x}_\tau} \log p_\tau(\boldsymbol{x}_\tau|y, \boldsymbol{s}_t). \quad (7)$$

第一項は学習した拡散モデルのスコアによって計算でき, 第二項は Clean Guidance を用いて式(8)のように求めることができる.

$$\nabla_{\boldsymbol{x}_\tau} \log p_\tau(\boldsymbol{x}_\tau|y, \boldsymbol{s}_t) = \nabla_{\boldsymbol{x}_\tau} J(\hat{\boldsymbol{x}_0}). \quad (8)$$

ここで,$\hat{\boldsymbol{x}}_0$ は各ステップ τ における拡散モデルによって計算されたノイズ除去後の $\boldsymbol{x}_\tau$ の推定値,J はクリーンガイダンスにおける損失関数で所与の条件 y によって柔軟に設定可能であるが,$\boldsymbol{x}_\tau$ に対して勾配計算可能でなければならない．本研究では壁とロボットの距離が離れるように条件付けしたいので，壁からロボットまでの相対位置 $\boldsymbol{p}_w$ を用いて損失関数を設計した．アルゴリズム 1に拡散モデルの行動生成誘導を利用した静的障害物回避のための行動生成を示す.

Algorithm 1: Action generation with guidance for static obstacle avoidance

Input: Pre-trained score network Ψ_θ, states $\boldsymbol{s}_t = [\boldsymbol{s}_t^r, \boldsymbol{s}_t^h]$ at time t, Position wall $\boldsymbol{p}_w$, safety distance d_s, hyperparameter η, T, $\bar{\alpha}_\tau$,σ_τ

$\boldsymbol{x}_T \sim \mathcal{N}(\boldsymbol{0}, \boldsymbol{I})$
for $\tau = T$ **to** 1 **do**
  $\hat{\boldsymbol{x}}_0 = \frac{1}{\sqrt{\bar{\alpha}_\tau}}\boldsymbol{x}_T - \frac{\sqrt{1-\bar{\alpha}_\tau}}{\sqrt{\bar{\alpha}_\tau}}\Psi_\theta(\boldsymbol{s}_t, \boldsymbol{x}_\tau, \tau)$
  $\mathcal{J}(\hat{\boldsymbol{x}}_0) = \exp(-||\boldsymbol{p}_w - \hat{\boldsymbol{x}}_0||^2)$
  $\tilde{\boldsymbol{x}}_0 = \hat{\boldsymbol{x}}_0 - \lambda\sigma_t\nabla_{\boldsymbol{x}_\tau}\mathcal{J}$
  $\boldsymbol{x}_{\tau-1} \sim \mathcal{N}(\mu_\tau(\tilde{\boldsymbol{x}}_0, \boldsymbol{x}_\tau), \sigma_t\boldsymbol{I})$
end
Excute action $\boldsymbol{a}_t = \boldsymbol{x}_0$

4. シミュレーション実験

本節では提案手法のシミュレーション実験を行い, 本手法の有効性を評価する.

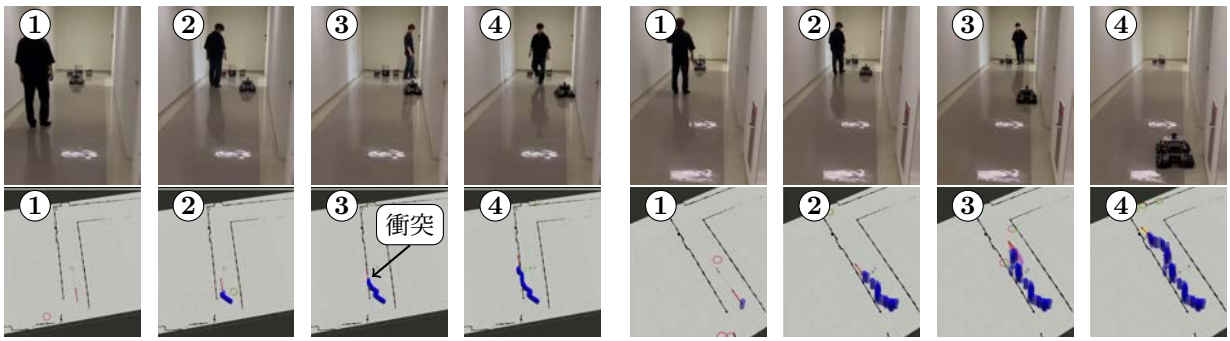

(a) ガイダンスなし行動生成　　(b) ガイダンス付き行動生成

図 2: 実環境における行動生成の比較．上段はカメラ画像, 下段は Rviz による軌跡.

4.1　シミュレーション環境

シミュレーション実験では,CrowdNav 環境を利用し, 独自のシナリオを作成した [1, 2]．本シナリオでは, ロボットは初期位置 $(x, y) = (0, -4)$ からゴール地点 $(x, y) = (0, 4)$ を目指して進む．歩行者は ORCA [7] に従って行動し, 初期化時に $x : -2 \sim 2$m に均等に,$y : 7 \sim 8$m に対してランダムに配置される.

4.2　定性評価

図 3にガイダンスを用いた場合の軌道の比較を示す.

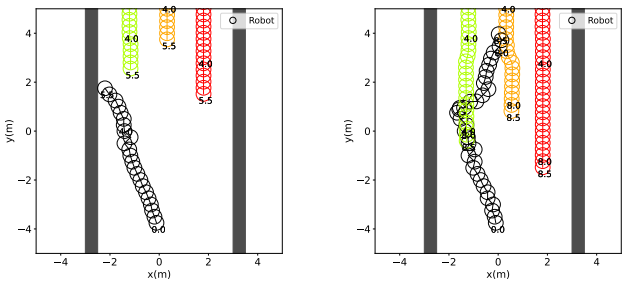

図 3: 障害物回避におけるガイダンスの軌道比較

図 3(a) より, ガイダンスなしではロボットが壁にぶつかってしまっていることがわかる．図 3(b) では壁への衝突が起こらないような軌跡になっており, ガイダンスを用いることで壁と歩行者を回避しゴールへ到達することができた.

4.3　定量評価

表 1にガイダンスを用いる場合と用いない場合の成功率, 歩行者への衝突率, 壁への衝突率, 到達時間, 収益の結果を示す.

表 1: 静的障害物が存在する環境における定量評価

Method	Success [%]↑	Col-P [%]↓	Col-W [%]↓	Exec. time [s]↓	Return↑
w/o guidance	52.8	**0.4**	46.8	8.00	0.261
w guidance	**95.6**	0.8	**3.6**	**7.99**	**0.645**

表 1よりガイダンスを行うことでほとんどのスコアが大きく増加していることが示せた．また, 歩行者への衝突率については 0.4% 低下したが, ガイダンスなしの手法で 46.8% の確率で歩行者に衝突する前に壁にぶつかってしまっており, 歩行者の回避回数が少ないことから, ガイダンスなしに比べて本手法をは十分に有用であることがわかる.

5.　実機実験

本節では提案手法の実機実験を行い, 本手法の有効性を評価する.

5.1　実験環境

本研究で使用した実験環境を図 4に示す.

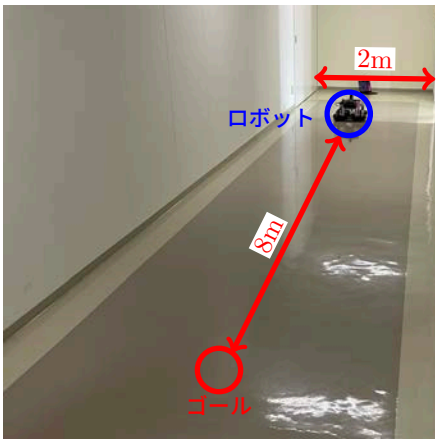

図 4: 実験環境

実験は図 4のような幅 2m の狭い通路で行った．ゴール座標はロボットから 8m 先の場所に設置し, その間に歩行者を配置し, 歩行者はすれ違うように移動を行った.

5.2　実験結果

図 2に実験の様子を示す.

図 2(a) より拡散モデルの行動生成では歩行者を回避した後に壁に衝突した．しかし,2(b) ではロボットは壁を回避し目的地へ到達することができた．これにより, 拡散モデルの行動生成をガイダンスを用いて壁を回避するように条件付けすることで実環境においても歩行者と壁を回避しゴールへ到達可能となり, 実機においても提案手法の有効性を確認することができた.

6. まとめと今後の展望

本研究では, 拡散モデルを用いた強化学習を歩行者が行き交う環境での移動ロボットナビゲーションに適用した．提案手法は, 学習済み拡散モデルに対して, 所与の条件付けを行うことで学習時と異なる環境に適応可能であることを示した．また, シミレーション実験, 実機実験によって本手法の有効性を確認した．

今後の展望としては, 行動生成速度の改善が挙げられる．5 節の実機実験では, 学習環境での時間間隔に行動生成が間に合わず, 処理の高速化が必要であることが分かった．現在のモデルでは 100 ステップかけて逆拡散過程を行い, 各逆拡散ステップでガイダンスを行うための損失関数を計算し, 行動を生成している．そのため, このステップを小さくすることで, 実世界においても所望時間以内の処理速度で高い性能を持った学習ができると考えている．

謝辞

本研究の一部は,JSPS 科研費 JP20H00230 の助成を受けたものである．

参 考 文 献

[1] Changan Chen, Yuejiang Liu, Sven Kreiss, and Alexandre Alahi: “Crowd-Robot Interaction: Crowd-aware Robot Navigation with Attention-based Deep Reinforcement Learning”, Proceedings of the IEEE International Conference on Robotics and Automation (ICRA), pp. 6015–6022, 2019.

[2] Changan Chen, Sha Hu, Payam Nikdel, Greg Mori, and Manolis Savva: “Relational Graph Learning for Crowd Navigation”, Proceedings of the IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS), pp. 10007–10013, 2020.

[3] Xueyou Zhang, Wei Xi, Xian Guo, Yongchun Fang, Bin Wang, Wulong Liu, and Jianye Hao: “Relational Navigation Learning in Continuous Action Space among Crowds”, Proceedings of the IEEE International Conference on Robotics and Automation (ICRA), pp. 3175–3181, 2021.

[4] Michael Psenka, Alejandro Escontrela, Pieter Abbeel, and Yi Ma: “Learning a Diffusion Model Policy from Rewards via Q-Score Matching”, Proceedings of the International Conference on Machine Learning (ICML), pp. 41163–41182, 2024.

[5] 富田湧, 松本耕平, 兵頭侑樹, 倉爪亮: “拡散モデルを利用した強化学習による歩行者混雑環境下での移動ロボットナビゲーション”, ロボティクス・メカトロニクス講演会, 2A1-O04, 2025.

[6] Davis Rempe, Zhengyi Luo, Xue Bin Peng, Ye Yuan, Kris Kitani, Karsten Kreis, Sanja Fidler, and Or Litany: “Trace and pace: Controllable pedestrian animation via guided trajectory diffusion”, IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), pp. 13756–13766, 2023.

[7] Jur Van Den Berg, Stephen J. Guy, Ming Lin, and Dinesh Manocha: “Reciprocal n-Body Collision Avoidance”, Proceedings of the International Symposium of Robotic Research, pp. 3–19, 2011.